

Trabalho LEA: Bandits

Pedro Ricardo Binhardi

Juliano Parasmio Pantani

10 de julho de 2026

Contents

1	Parte 1	1
1.1	Resultados da Simulação	1
1.2	Respostas às Perguntas da Parte 1	2
2	Parte 2	2
2.1	Avaliação de Políticas	3
2.2	Respostas às Perguntas da Parte 2	3


1 Parte 1

Nesta seção, analisamos um problema de bandit com espaço de ações $\mathcal{A} = \{1, \dots, 5\}$. As recompensas seguem uma distribuição normal, onde $R_t|a_t = a \sim \mathcal{N}(\mu_a, \sigma^2)$ com variância conhecida $\sigma = 1$. Para o estudo de simulação, assumimos o caso nulo onde não há superioridade entre os braços, ou seja, $\mu_1 = \mu_2 = \dots = \mu_5 = 0$. O objetivo é avaliar o comportamento do intervalo de confiança de 95% usual para o braço selecionado empiricamente como o melhor, denotado por $\hat{a} = \arg \max_{a \in \mathcal{A}} \hat{\mu}_a$. O intervalo ingênuo construído é $\hat{\mu}_{\hat{a}} \pm 1.96\sigma/\sqrt{n_{\hat{a}}}$.

1.1 Resultados da Simulação

A simulação consistiu em replicar o experimento 1.000 vezes para cada política, com um horizonte de $T = 500$ passos. A cobertura empírica dos intervalos de confiança nominais de 95% está resumida na tabela abaixo e a distribuição das médias do braço vencedor é ilustrada no gráfico.

Política	Cobertura Empírica	Média de $\hat{\mu}_{\hat{a}}$
greedy	0.938	0.011
ts	0.923	0.068
ucb	0.922	0.081
uniform	0.870	0.120



1.2 Respostas às Perguntas da Parte 1

1. *A cobertura empírica fica próxima de 95% para todos os procedimentos?*

Não. A cobertura empírica fica sistematicamente abaixo de 95% para todas as políticas, sendo o erro ainda mais drástico em políticas que exploram menos ativamente. Isso ocorre pois, ao tratarmos a seleção do braço $\hat{a}$ como se tivesse sido feita antes da observação dos dados, ignoramos o viés de seleção. O braço selecionado como o “melhor” frequentemente é aquele que sofreu uma realização positiva de ruído aleatório.

2. *Como as diferentes políticas afetam a distribuição de $\hat{\mu}_{\hat{a}}$?*

As políticas de alocação alteram a distribuição de $\hat{\mu}_{\hat{a}}$ deslocando-a para a direita (viés positivo) e modificando sua variância. Em políticas adaptativas, como Thompson Sampling e UCB, a adaptação temporal envia um volume maior de tráfego para braços com bom desempenho aparente precoce. Isso intensifica o deslocamento da distribuição amostral do vencedor em relação à verdadeira média nula ($\mu = 0$).

3. *Por que esse fenômeno é relevante em testes A/B, ensaios clínicos adaptativos ou seleção de modelos?*

Em testes A/B online e ensaios clínicos adaptativos, os algoritmos tentam alocar mais amostras aos melhores tratamentos enquanto ainda aprendem. Como a alocação de amostras depende dos resultados observados iterativamente, os intervalos de confiança e p-valores ingênuos não mantêm sua interpretação estatística padrão. Ignorar esse fenômeno leva à superestimação severa dos tamanhos de efeito (a “maldição do vencedor”) e ao aumento da taxa de falsos positivos na tomada de decisão.


2 Parte 2

Recompensa acumulada em um exemplo Poisson Para o problema de maximização de novos cadastros diários, utilizamos um modelo de recompensas onde $R_t|a_t = a \sim \text{Poisson}(\lambda_a)$, com taxas verdadeiras $\lambda = (18, 20, 21, 23, 27)$. O objetivo é maximizar a recompensa acumulada $\sum_{t=1}^T R_t$.

Escolha da Priori: As prioris adotadas para as taxas são independentes e modeladas como $\lambda_a \sim \text{Gamma}(\alpha_0, \beta_0)$. Como as taxas esperadas estão em torno de 20 a 30 cadastros, escolhemos $\alpha_0 = 2$ e $\beta_0 = 0.1$. Essa parametrização fornece uma esperança a priori de $\mathbb{E}[\lambda] = \alpha_0/\beta_0 = 20$ e uma variância relativamente alta de 200, caracterizando uma priori fracamente informativa, mas centralizada na ordem de grandeza correta do problema empírico.

2.1 Avaliação de Políticas

Abaixo observamos a recompensa acumulada das cinco estratégias ao longo de $T = 1000$ períodos, baseada em 100 simulações.



2.2 Respostas às Perguntas da Parte 2

1. Quais políticas obtêm maior recompensa acumulada?

As políticas Thompson Sampling (TS) e Upper Confidence Bound (UCB) são as que alcançam a maior recompensa acumulada ao longo do experimento. Em análises empíricas de cenários multi-armed bandits, as curvas de desempenho acumulado dessas duas abordagens apresentam o crescimento mais acentuado. Isso ocorre porque ambos os métodos conseguem mitigar o custo da exploração inicial, identificando rapidamente qual campanha possui a maior taxa média de novos cadastros (λ_a) para passar a explorá-la de forma consistente.

2. Quais políticas exploram mais? Quais exploram menos?

Alocação Uniforme Aleatória: É a política que mais realiza exploração no sistema. Por ser um baseline sem capacidade de aprendizado, ela distribui as interações inteiramente ao acaso entre as cinco campanhas durante todo o horizonte de tempo, ignorando o histórico de recompensas.

ϵ -Greedy: Apresenta uma taxa de exploração constante e fixa. Sob essa abordagem, o algoritmo continua gastando recursos explorando opções sabidamente subótimas com uma probabilidade estável ϵ , mesmo em estágios avançados do experimento.

Thompson Sampling e UCB: Realizam uma exploração inteligente e balanceada, guiada diretamente pelo nível de incerteza dos parâmetros. À medida que o volume de dados aumenta e a variância das estimativas diminui, a necessidade de explorar decresce naturalmente.

Greedy (Míope): É a estratégia que menos explora. Ela foca de maneira estritamente imediata na exploração do braço que apresenta a maior média a posteriori no instante atual, sem atribuir valor estatístico à coleta de novas informações.

3. A política greedy é competitiva? Em que situações ela falha?

Não, a política greedy não se mostra competitiva a longo prazo, apresentando um desempenho acumulado estatisticamente inferior e pouco confiável se comparado às abordagens adaptativas. O método falha criticamente devido à sua alta suscetibilidade a flutuações amostrais iniciais. Se um braço excelente (como a campanha 5, que possui $\lambda = 27$) sofrer uma realização de ruído estocástico desfavorável em suas primeiras puxadas, sua média calculada será artificialmente baixa. Como a estratégia míope seleciona apenas o braço com o maior estimador pontual do momento, ela deixará de testar a campanha correta e ficará permanentemente presa em uma alternativa subótima que teve sorte inicial.

4. A política que maximiza recompensa acumulada também estima bem todos os λ_a ?

Não. Há um trade-off e uma distinção fundamental entre o objetivo científico de estimar com precisão o efeito de todos os tratamentos e o objetivo prático de maximizar a recompensa cumulativa durante o processo. Para maximizar o número total de cadastros, algoritmos eficientes como UCB e Thompson Sampling direcionam rapidamente o tráfego de usuários para as versões de melhor desempenho aparente. Consequentemente, as campanhas com pior desempenho (como as de menor taxa λ_a) deixam de ser selecionadas e acumulam pouquíssimas observações, fazendo com que a incerteza e a variância de suas estimativas permaneçam elevadas.

5. O modelo Poisson é adequado para o exemplo? Quais limitações ele tem?

O modelo Poisson funciona bem como uma aproximação de partida por se tratar de um modelo natural para dados de contagem inteiros e não-negativos, como novos cadastros por dia. Contudo, ele impõe limitações restritivas:

Equidispersão: A distribuição Poisson impõe teoricamente que a variância dos dados deve ser estritamente igual à sua média ($\mathbb{E}[R_t] = \text{Var}(R_t) = \lambda_a$). Na prática de tráfego web, os dados reais comumente sofrem de sobredispersão (variância muito maior que a média) gerada por picos de acessos sazonais ou engajamentos em massa.

Independência Temporal: Assume-se que as ocorrências de cadastros em um dia são independentes do dia anterior, desconsiderando o efeito de fadiga da campanha publicitária ou tendências macroeconômicas ao longo do tempo.

6. Que mudanças no modelo seriam necessárias para tornar o exemplo mais realista?

Para aproximar o experimento de uma aplicação real de mercado, seriam sugeridas as seguintes evoluções estruturais:

Modelagem de Bandit Contextual: Em vez de assumir uma taxa fixa por campanha para qualquer usuário, o sistema deve registrar um vetor de características ou contexto do visitante (idade, localização, comportamento de navegação recente). Isso permitiria que o algoritmo personalizasse a exibição, entendendo que a melhor ação depende diretamente do perfil de quem acessa o site.

Adoção de Distribuições Flexíveis: Substituir a verossimilhança Poisson por uma distribuição Binomial Negativa, o que adiciona um parâmetro de forma capaz de acomodar e modelar a sobredispersão inerente ao comportamento digital dos usuários.

Dinâmica Não-Estacionária: Permitir que os parâmetros das taxas de conversão alterem-se com o passar do tempo, refletindo o desgaste natural das peças publicitárias (saturação) ou variações sazonais de mercado.